



UNIVERSITATEA DIN
BUCUREȘTI
— VIRTUTE ET SAPIENTIA

Aspecte computaționale în producerea de cuvinte

Lucrare de Licență
Maria-Smaranda Pandele
22 Iunie, 2019

Coordonator: Prof. Dr. Liviu Dinu
Facultatea de Matematică și Informatică, UNIBUC

Rezumat

This example thesis briefly shows the main features of our thesis style, and how to use it for your purposes.

Cuprins

Cuprins	iii
1 Introduction	1
1.1 Features	1
1.1.1 Extra package includes	1
1.1.2 Layout setup	2
1.1.3 Theorem setup	2
1.1.4 Macro setup	3
2 Introducere	5
3 Reconstrucție de cuvinte	7
4 Agregarea rezultatelor folosind distanța rank	9
4.1 Clasamente și distanța rank	9
4.1.1 Agregări cu distanța rank	10
4.1.2 Reducerea la o problemă de cuplaj perfect de cost minim	11
4.1.3 Calcularea tuturor agregărilor optime	12
4.2 Determinarea tuturor agregărilor producțiilor de cuvinte . . .	13
5 Rezultate	15
6 Concluzii	17
A Dummy Appendix	19
Bibliografie	21

Capitolul 1

Introduction

This is version v1.4 of the template.

We assume that you found this template on our institute's website, so we do not repeat everything stated there. Consult the website again for pointers to further reading about L^AT_EX. This chapter only gives a brief overview of the files you are looking at.

1.1 Features

The rest of this document shows off a few features of the template files. Look at the source code to see which macros we used!

The template is divided into T_EX files as follows:

1. `thesis.tex` is the main file.
2. `extrapackages.tex` holds extra package includes.
3. `layoutsetup.tex` defines the style used in this document.
4. `theoremsetup.tex` declares the theorem-like environments.
5. `macrosetup.tex` defines extra macros that you may find useful.
6. `introduction.tex` contains this text.
7. `sections.tex` is a quick demo of each sectioning level available.
8. `refs.bib` is an example bibliography file. You can use BibT_EX to quote references. For example, read if you can get a hold of it.

1.1.1 Extra package includes

The file `extrapackages.tex` lists some packages that usually come in handy. Simply have a look at the source code. We have added the following com-

ments based on our experiences:

REC This package is recommended.

OPT This package is optional. It usually solves a specific problem in a clever way.

ADV This package is for the advanced user, but solves a problem frequent enough that we mention it. Consult the package's documentation.

As a small example, here is a reference to the Section *Features* typeset with the recommended *varioref* package:

See Section 1.1 on the preceding page.

1.1.2 Layout setup

This defines the overall look of the document – for example, it changes the chapter and section heading appearance. We consider this a 'do not touch' area. Take a look at the excellent *Memoir* documentation before changing it.

In fact, take a look at the excellent *Memoir* documentation, full stop.

1.1.3 Theorem setup

This file defines a bunch of theorem-like environments.

Teoremă 1.1 *An example theorem.*

Proof Proof text goes here. □

Note that the q.e.d. symbol moves to the correct place automatically if you end the proof with an `enumerate` or `displaymath`. You do not need to use `\qedhere` as with *amsthm*.

Teoremă 1.2 (Some Famous Guy) *Another example theorem.*

Proof This proof
1. ends in an enumerate. □

Propoziție 1.3 *Note that all theorem-like environments are by default numbered on the same counter.*

Proof This proof ends in a display like so:

$$f(x) = x^2. \quad \square$$

1.1.4 Macro setup

For now the macro setup only shows how to define some basic macros, and how to use a neat feature of the *mathtools* package:

$$|a|, \quad \left|\frac{a}{b}\right|, \quad \left|\frac{a}{b}\right|.$$

Capitolul 2

Introducere

Capitolul 3

Reconstrucție de cuvinte

Capitolul 4

Agregarea rezultatelor folosind distanța rank

Am văzut cum putem obține producții de cuvinte combinând câte o singură limbă romanică cu limba latină. Pentru a îmbunătăți rezultatele vrem să folosim informația din mai multe limbi romanice moderne. Astfel, fiecare clasificator întoarce o listă ordonată de cuvinte latinești, pe prima poziție aflându-se perechea cognate cu cea mai mare probabilitate. Prin agregarea acestora cu o anumită metrică vom obține cele mai probabile perechi cognate.

4.1 Clasamente și distanța rank

Un *clasament* este o listă ordonată de obiecte după un anumit criteriu, pe prima poziție aflându-se cel cu cea mai mare importanță. În unele situații se pune problema găsirii unui clasament cât mai apropiat de o mulțime de mai multe clasamente. Pentru a rezolva această problemă trebuie să definim mai întâi ce înseamnă distanța dintre două clasamente sau dintre un singur clasament și o mulțime de clasamente.

Există mai multe metrice folosite cu succes în diverse aplicații: distanța *Kedall tau*, *Spearman footrule*, *Levenshtein*, dar noi vom folosi distanța *rank* introdusă în articolul [2]. În întregul capitol vom folosi următoarele notații:

- $U = \{1, 2, \dots, n\}$ o mulțime finită de obiecte numită univers
- $\tau = (x_1 > x_2 > \dots > x_d)$ un clasament peste universul U
- $>$ o relație de ordine strictă reprezentând criteriul de ordonare
- $\tau(x)$ = poziția elementului $x \in U$ în clasamentul τ dacă $x \in \tau$, numerotând pozițiile de la 1 începând cu cel mai important obiect din clasament

Dacă un clasament conține toate elementele din univers, atunci el se va numi *clasament total*. Asemănător, dacă conține doar o submulțime de obiecte din univers, atunci îl vom numi *clasament parțial*.

Notăm ordinea elementului x în τ astfel:

$$\text{ord}(\tau, x) = \begin{cases} |n + 1 - \tau(x)| & , x \in \tau \\ 0 & , x \in U \setminus \tau \end{cases} \quad (4.1)$$

Definiție 4.1 Fie τ și σ două clasamente parțiale peste același univers U . Atunci distanța rank va fi

$$\Delta(\tau, \sigma) = \sum_{x \in \tau \cup \sigma} |\text{ord}(\tau, x) - \text{ord}(\sigma, x)| \quad (4.2)$$

Se observă faptul că, în calculul distanței rank, se ia în considerare ordinea definită mai sus și nu poziția. În primul rând, cum primele poziții sunt cele mai importante, distanța dintre două clasamente trebuie să fie cu atât mai mare cu cât diferă mai mult începutul lor.[6] În al doilea rând, definiția funcției *ord* pune accentul pe lungimea clasamentelor întrucât putem presupune că un clasament mai lung a fost obținut în urma comparării mai multor obiecte din univers. Deci ordinea elementelor este mai solidă. Spre exemplu, dacă două clasamente de lungimi diferite au același element pe prima poziție, există totuși o diferență a ordinii obiectului în cele două liste, diferență ce contribuie la calculul distanței rank totale.[3]

4.1.1 Agregări cu distanța rank

O *agregare de clasamente* reprezintă un singur clasament σ astfel încât o anumită metrică de la acesta la mulțimea de liste de agregat T este minimă. Raportându-ne la distanța rank avem[2]:

Definiție 4.2 Fie un set de clasamente $T = \{\tau_1, \tau_2, \dots, \tau_m\}$ dintr-un univers U și $\sigma = (\sigma_1 > \sigma_2 > \dots > \sigma_k)$ un clasament astfel încât $\sigma_i \in U, \forall 1 \leq i \leq k$. Definim distanța rank de la σ la T astfel:

$$\Delta(\sigma, T) = \sum_{i=1}^m \Delta(\sigma, \tau_i) \quad (4.3)$$

Definiție 4.3 Se numește *multime de agregări de lungime k a mulțimii T folosind distanța rank*, setul $A(T, k) = \{\sigma = (\sigma_1 > \sigma_2 > \dots > \sigma_k) | \sigma_i \in U, \forall 1 \leq i \leq k, \text{ și } \Delta(\sigma, T) \text{ este minim posibilă} \}$

Problemă 4.4 Fie U un set de obiecte și $T = \{\tau_1, \tau_2, \dots, \tau_m\}$ o multime de clasamente peste universul U . Vrem să determinăm mulțimea de agregări $A(T, k)$ pentru un k fixat.

Construim următoarele matrici bidimensionale $W^k(i, j)$ cu n linii și n coloane. Fiecare celulă din fiecare matrice reprezintă costul total din distanța rank de la un clasament σ , de lungime l , către o mulțime $T = \{\tau_1, \tau_2, \dots, \tau_m\}$ fixată indus de plasarea elementului $x_i \in U$ pe poziția j în σ [3]. Se observă faptul că un clasament peste universul U definit mai sus poate avea lungimea maxim n . Rezultă că numărul de coloane al matricilor W^t este egal cu n .

$$W^k(i, j) = \begin{cases} \sum_{p=1}^m |\text{ord}(p, i) - k + j| & , j \leq k \\ \sum_{p=1}^m |\text{ord}(p, i)| & , j > k \end{cases} \quad (4.4)$$

Propoziție 4.5 Distanța de la un clasament $\sigma = (\sigma_1 > \sigma_2 > \dots \sigma_k)$ la mulțimea T este

$$\Delta(\sigma, T) = \sum_{x_i \in U \cap \sigma} W^k(i, \sigma(x_i)) + \sum_{x_i \in U \setminus \sigma} W^k(i, k+1)$$

unde n reprezintă numărul de obiecte din univers, iar $k < n$.

Se observă faptul că, în cazul în care σ conține toate elementele din U , deci cazul $k = n$, formula se devine

$$\Delta(\sigma, T) = \sum_{x_i \in U \cap \sigma} W^k(i, \sigma(x_i)) \quad (4.5)$$

4.1.2 Reducerea la o problemă de cuplaj perfect de cost minim

Fiecare matrice W^l din secțiunea precedentă este calculată în mod independent de celelalte. Deci putem determina doar o singură matrice pentru o anumită lungime fixată l . Astfel, problema se reduce la găsirea unui clasament σ ce minimizează formula (4.5). Formal:

Problemă 4.6 Fiind dată o matrice pătratică W , $W = (w_{i,j})_{1 \leq i,j \leq n}$ vrem să determinăm următoarea mulțime:

$$S = \{(i_1, i_2, \dots, i_n) | (i_p \neq i_j, \forall p \neq j), (i_j \in U) \text{ și } \sum_{j=1}^n w_{i,j} \text{ este minim}\}$$

Problema de mai sus se aseamănă cu o problemă de cuplaj perfect de cost minim întrucât vrem să formăm perechi între obiectele dintr-un univers și pozițiile unui clasament de tip agregare, iar fiecare combinație are un anumit cost. Practic (i_1, i_2, \dots, i_n) reprezintă o permutare a elementelor din U .

O soluție pentru a rezolva problema precedentă este aplicarea algoritmului Ungar prezentat de Khun [4]. Altfel, putem considera matricea W ca fiind o matrice de costuri într-un graf bipartit G pe care aplicăm un algoritm clasic

de gasire a cuplajului maxim de cost minim. Conform [7] aceasta problema poate fi rezolvata in timp polinomial $\mathcal{O}(n^3)$ construind o retea de flux cu capacitati convenabile si prin gasirea unor drumuri de augmentare minime, din punct de vedere al costului, folosind algoritmul lui Dijkstra[1].

Toate aceste rezolvari determina o singura agregare dar nu si pe toate, adica multimea $A(T, k)$ din definitia 4.3. In continuare prezentam o metoda de determinare a tuturor agregarilor bazata pe gasirea tuturor cuplajelor perfecte de cost minim dintr-un graf, metoda prezentata in [5]. Algoritmul ruleaza intr-un timp polinomial. Particularizam problemele si algoritmi din articolul *A generalization of the assignment problem, and its application to the rank aggregation problem* [5] pentru Problema 4.6.

4.1.3 Calcularea tuturor agregărilor optime

Reamintim faptul ca dorim sa calculam multimea de agregari $A(T, k)$, stiind costul plasarii fiecarui element pe fiecare pozitie, memorat in matricea W^k calculata la (4.4). Reformulam problema in elemente de teoria grafurilor. Astfel, asociem Problemei 4.6 un graf $G = (V, E, c, w)$, unde V reprezintă multimea de noduri, E este multimea de muchii iar $c: E \rightarrow \mathbb{N}$ si $w: E \rightarrow \mathbb{N}$ reprezinta capacitatea unei muchii respectiv costul acesteia. Legaturile intre Problema 4.6 si graful G sunt:

- $V = \{src, dst\} \cup U \cup \{1, 2, \dots, k\}$
- $E = \{(src, x_i) | x_i \in U\} \cup \{(x_i, j) | x_i \in U \text{ si } j = 1, \dots, k\} \cup \{(j, dst) | j = 1, \dots, k\}$
- $c(muchie) = 1, \forall muchie \in E$:
- functia w astfel:
 - $w((src, x_i)) = 0, \forall x_i \in U$
 - $w((x_i, j)) = W^k(i, j), \forall x_i \in U, j = 1, \dots, k$
 - $w((j, dst)) = 0, j = 1, \dots, k$

Se poate calcula usor in acest graf un cuplaj maxim de cost minim folosind algoritmi clasici (metoda Ungara [4] sau prin aflarea fluxului maxim de cost minim[7]). Notam prin $solve(W)$ un asemenea algoritim. Fie solutia $M = \{(x, j) | x \in U \text{ si } j = 1, \dots, k\}$. Urmatorul pas este aflarea unei solutii M' diferite de M .

Propoziție 4.7 Doua cuplaje M si M' sunt diferite daca exista cel putin o pereche (x, y) care se afla in M si nu se afla in M' .

Astfel, propunem urmatorul algoritim, adaptat din [5], prin care cautam o a doua solutie M' fixand cate o muchie candidat (x, y) prin care M' sa difere

4.2. Determinarea tuturor agregărilor producțiilor de cuvinte

de M . Setand costul muchiei (x, y) pe o valoare infinita, avem garantia ca aceasta nu va fi luata in considerare in constructia lui M' .

Algorithm 1 Calculeaza M'

Input: W, M

Output: M'

```
 $s \leftarrow \sum_{(u,v) \in M} w_{uv}$ 
for all  $(x, y) \in M$  do
   $temp \leftarrow w_{xy}$ 
   $w_{xy} \leftarrow \infty$ 
   $M' \leftarrow solve(W)$ 
  if  $M' \neq \emptyset$  si  $\sum_{(u,v) \in M'} w_{uv} = s$  then
    return  $M'$ 
  else
     $w_{xy} \leftarrow temp$ 
  end if
end for
return  $\emptyset$ 
```

Algoritmul returneaza fie multimea vida, fie o solutie M' astfel incat exista o pereche $(x, y) \in M \setminus M'$. Se poate imparti problema initiala in doua subprobleme disjuncte P_1 si P_2 :

- P_1 : multimea tuturor cuplajelor ce contin muchia (x, y)
- P_2 : multimea tuturor cuplajelor ce **nu** contin muchia (x, y)

Evident, exista deja cate o solutie calculata pentru cele 2 subprobleme si anume $M \in P_1$ si $M' \in P_2$. Prim urmare, se poate aplica Algoritmul 4.1.3 in mod recursiv pentru fiecare dintre aceste subprobleme pentru a determina intreaga multime de solutii. Aceasta abordare conduce la construirea unei structuri de cautare arborescente in care radacina reprezinta problema initiala ??, iar fiecare nod intern constituie o impartire pe subprobleme dupa o pereche (x, y) . Solutia finala se construiesc traversand arborele in adancime si pastrand toate solutiile parțiale calculate la fiecare pas. Nu se va genera aceeasi solutie de mai multe ori prin faptul ca problemele P_1 si P_2 sunt complet disjuncte.

4.2 Determinarea tuturor agregărilor producțiilor de cuvinte

În capitolul precedent am prezentat o metoda de a combina o limbă romanică modernă si limba latină pentru a automatiza procesul de determinare a etimonului latinesc. Metoda returna primele n cuvinte posibile ordonate

de la cel cu probabilitatea cea mai mare la cel cu probabilitatea cea mai mică. Vom considera aceste liste de cuvinte ca fiind clasamente. Pentru fiecare cuvânt latinesc vom agrega clasamentele produse din fiecare limbă romanică modernă (*ro, it, fr, es, pt*). Se observă faptul că pot exista mai multe astfel de agregări așa că ne propunem să le aflăm pe toate într-un mod eficient din punct de vedere al complexității timp. Alegem să luăm în considerare doar primele 5 cele mai bune cuvinte din fiecare set. Astfel, pentru un singur cuvânt latinesc, vom avea:

$$R = \{r_1, r_2, \dots, r_k\}, \text{clasamentele produse din ro, it, fr, es, pt}$$

$$k = |R|, 1 \leq k \leq 5$$

$$U = \bigcup_{i=1}^k r_i \text{ universul de cuvinte}$$

$$n = |U|$$

Definim o matrice bidimensională de k linii și n coloane în care calculăm ordinea fiecărui cuvânt din univers în fiecare clasament dat:

$$ord[i][j] = \begin{cases} |6 - r_i(x_j)| & , x_j \in r_i \\ 0 & , x_j \in U \setminus r_i \end{cases}$$

Capitolul 5

Rezultate

Capitolul 6

Concluzii

Anexa A

Dummy Appendix

You can defer lengthy calculations that would otherwise only interrupt the flow of your thesis to an appendix.

Bibliografie

- [1] T.H. Cormen, C.E. Leiserson, R.L. Rivest, and C. Stein. *Introduction to Algorithms*, chapter 24, pages 504–507. MIT Press and McGraw-Hills, 2 edition, 2001.
- [2] L.P. Dinu. On the classification and aggregation of hierarchies with different constitutive elements. *Fund. Inform.* 55 (1), pages 39–50, 2003.
- [3] L.P. Dinu and F. Manea. An efficient approach for the rank aggregation problem. *Theoretical Computer Science vol 359(1-3)*, pages 455–461, 2006.
- [4] H.W. Kuhn. The Hungarian method for assignment problem. *Naval Res. Logist. Quarterly* 2, pages 83–97, 1955.
- [5] F. Manea and C. Ploscaru. A generalization of the assignment problem, and its application to the rank aggregation problem. *Fundamenta Informaticae* 81, pages 459–471, 2007.
- [6] S. Marcus. Linguistic structures and generative devices in molecular genetics. *Cahiers Ling. Theor. Appl.*, pages 77–101, 1974.
- [7] R.Jonker and T.Volgenant. A shortest augmenting path algorithm for dense and sparse linear assignment problems. *Computing* 38, pages 5(1): 325–340, 1987.